Perbandingan RNN, LSTM, dan GRU: Konsep, Arsitektur, dan Studi Kasus

Laporan Komparatif Arsitektur Recurrent Neural Network

1. Pendahuluan

Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU) adalah tiga arsitektur jaringan saraf tiruan yang dirancang untuk memproses data berurutan (sequential data), seperti teks, suara, deret waktu, video, dan data sensor. Perbedaan utamanya terletak pada cara masing-masing model menyimpan dan mengatur informasi dari waktu ke waktu.

RNN dasar menggunakan hidden state sebagai memori jangka pendek. Namun, RNN dasar sering mengalami kesulitan mempelajari hubungan jangka panjang karena masalah vanishing gradient dan exploding gradient. LSTM dan GRU dikembangkan untuk mengatasi kelemahan tersebut dengan menambahkan mekanisme gerbang (gating mechanism).

2. Konsep Dasar Data Berurutan

Data berurutan adalah data yang urutannya memiliki makna. Contohnya:

- Kalimat: “Harga saham naik karena permintaan meningkat.”
- Sinyal EKG pasien dari waktu ke waktu.
- Harga saham harian.
- Konsumsi listrik per jam.
- Data curah hujan dan debit sungai.

Pada data berurutan, informasi sebelumnya sering memengaruhi interpretasi informasi berikutnya. Oleh karena itu, model tidak cukup hanya melihat satu titik data, tetapi juga harus “mengingat” konteks sebelumnya.

3. Recurrent Neural Network (RNN)

3.1 Pengertian RNN

RNN (Recurrent Neural Network) adalah jaringan saraf yang memiliki koneksi berulang (recurrent connection). Berbeda dengan feedforward neural network biasa yang memproses setiap input secara independen, RNN meneruskan informasi dari satu langkah waktu ke langkah waktu berikutnya.

RNN cocok digunakan untuk masalah seperti:

- Prediksi deret waktu.
- Klasifikasi teks.
- Pengenalan suara.

- Pemodelan bahasa.
- Deteksi anomali pada data sensor.

3.2 Hidden State pada RNN

Hidden state adalah representasi internal yang berfungsi sebagai memori jangka pendek model. Pada setiap langkah waktu t, RNN menerima dua masukan:

- Input baru pada waktu t, yaitu x_t.
- Hidden state sebelumnya, yaitu h_{t-1}.

Secara sederhana, perhitungan hidden state RNN dapat ditulis:

```
h_t = tanh(W_x * x_t + W_h * h_{t-1} + b)
```

Keterangan:

- x_t = input pada waktu t
- h_{t-1} = hidden state atau ingatan dari waktu sebelumnya
- h_t = hidden state baru
- W_x = bobot untuk input
- W_h = bobot untuk hidden state sebelumnya
- b = bias
- tanh = fungsi aktivasi

Dengan formula tersebut, output pada waktu t tidak hanya bergantung pada x_t, tetapi juga pada seluruh informasi penting yang telah diproses sebelumnya.

3.3 Kelemahan RNN

Kelemahan utama RNN dasar adalah vanishing gradient. Ketika urutan data sangat panjang, gradien yang digunakan untuk memperbarui bobot dapat mengecil terus-menerus selama proses backpropagation through time. Akibatnya, model sulit mempelajari hubungan antara informasi awal dan informasi akhir.

Sebagai contoh, pada kalimat: “Negara tersebut mengalami krisis ekonomi selama beberapa tahun, sehingga harga barang akhirnya naik.” RNN dasar mungkin kesulitan menghubungkan kata “harga barang akhirnya naik” dengan konteks “krisis ekonomi” yang berada jauh di awal kalimat.

4. Long Short-Term Memory (LSTM)

4.1 Pengertian LSTM

LSTM (Long Short-Term Memory) adalah pengembangan dari RNN yang diperkenalkan oleh Hochreiter dan Schmidhuber pada tahun 1997. LSTM dirancang khusus untuk menyimpan informasi dalam jangka waktu yang lebih lama melalui struktur yang disebut memory cell atau cell state.

LSTM banyak digunakan pada: pengenalan tulisan tangan, pengenalan suara, prediksi deret waktu, pemrosesan bahasa alami, prediksi medis dan biologi, serta analisis teks dan sentimen.

4.2 Komponen Utama LSTM

LSTM memiliki tiga komponen penting:

Komponen	Fungsi
Cell state (C_t)	Jalur memori jangka panjang yang membawa informasi penting dari waktu ke waktu.
Hidden state (h_t)	Memori jangka pendek yang digunakan untuk menghasilkan output pada waktu tertentu.
Gates	Mekanisme pengatur informasi yang masuk, disimpan, dibuang, atau dikeluarkan.

4.3 Tiga Gerbang LSTM

LSTM menggunakan tiga gerbang utama:

- Forget gate: Menentukan informasi lama mana yang perlu dibuang dari cell state.
- Input gate: Menentukan informasi baru mana yang layak disimpan ke dalam cell state.
- Output gate: Menentukan bagian cell state yang akan digunakan untuk menghasilkan output atau hidden state baru.

Secara konseptual:

```
C_t = f_t ⊙ C_{t-1} + i_t ⊙ C~_t
```

Keterangan: C_{t-1} = memori jangka panjang sebelumnya, f_t = forget gate, i_t = input gate, C~_t = kandidat informasi baru, C_t = memori jangka panjang baru, ⊙ = perkalian elemen-demi-elemen.

4.4 Mengapa LSTM Memiliki Memori Jangka Panjang?

LSTM mampu menyimpan informasi jangka panjang karena memiliki cell state yang dapat meneruskan informasi melalui banyak langkah waktu tanpa harus selalu mengalami transformasi ulang seperti hidden state pada RNN biasa. Gerbang forget, input, dan output mengatur informasi tersebut secara selektif.

Dengan demikian, LSTM dapat memutuskan:

- Informasi mana yang penting untuk diingat.
- Informasi mana yang sudah tidak relevan dan dapat dilupakan.
- Informasi mana yang perlu digunakan untuk prediksi saat ini.

5. Gated Recurrent Unit (GRU)

5.1 Pengertian GRU

GRU (Gated Recurrent Unit) adalah varian RNN bergerbang yang diperkenalkan oleh Cho et al. pada tahun 2014. GRU merupakan penyederhanaan dari LSTM karena menggunakan lebih sedikit gerbang dan parameter, tetapi tetap mampu menangkap ketergantungan jangka panjang pada banyak kasus.

GRU sering dipilih ketika dataset tidak terlalu besar, komputasi perlu lebih efisien, model LSTM terlalu kompleks, dan performa LSTM serta GRU relatif setara.

5.2 Komponen Utama GRU

GRU memiliki dua gerbang utama:

Gerbang	Fungsi
Update gate	Menentukan seberapa banyak informasi lama yang dipertahankan dan seberapa banyak informasi baru yang diterima.
Reset gate	Menentukan seberapa besar informasi lama yang diabaikan saat menghitung kandidat hidden state baru.

Berbeda dengan LSTM, GRU tidak memiliki cell state terpisah. GRU hanya menggunakan hidden state untuk menyimpan informasi dari waktu ke waktu.

5.3 Cara Kerja GRU

Update gate berfungsi menyeimbangkan memori lama dan informasi baru:

```
h_t = z_t ⊙ h_{t-1} + (1 - z_t) ⊙ h~_t
```

Keterangan: z_t = update gate, h_{t-1} = hidden state sebelumnya, h~_t = kandidat hidden state baru, h_t = hidden state baru.

Jika z_t mendekati 1, model lebih banyak mempertahankan informasi lama. Jika z_t mendekati 0, model lebih banyak menggunakan informasi baru.

6. Perbandingan RNN, LSTM, dan GRU

Aspek	RNN	LSTM	GRU
Tahun Pengembangan	Konsep dasar lebih awal	1997	2014
Jumlah Gerbang	Tidak ada gerbang	3 gerbang (forget, input, output)	2 gerbang (update, reset)
Memori Jangka Pendek	Hidden state	Hidden state	Hidden state

Memori Jangka Panjang	Lemah	Kuat melalui cell state	Cukup kuat melalui update gate
Cell State Terpisah	Tidak ada	Ada	Tidak ada
Jumlah Parameter	Paling sedikit	Paling banyak	Lebih sedikit dari LSTM
Kecepatan Pelatihan	Cepat, tetapi sering tidak stabil	Lebih lambat	Lebih cepat dari LSTM
Ketahanan Vanishing Gradient	Rendah	Tinggi	Tinggi
Kompleksitas	Rendah	Tinggi	Sedang
Aplikasi Sesuai	Urutan pendek	Urutan panjang & kompleks	Urutan menengah hingga panjang (efisien)

RNN paling sederhana karena hanya mengandalkan hidden state. LSTM lebih kompleks karena memiliki cell state dan tiga gerbang, sedangkan GRU berada di antara keduanya: lebih sederhana daripada LSTM tetapi lebih baik daripada RNN dasar dalam menangani dependensi jangka panjang.

7. Mengapa Hidden State dan Memori Diperlukan?

7.1 Hidden State

Hidden state diperlukan agar model dapat memahami konteks. Tanpa hidden state, setiap input diproses secara terpisah dan model tidak dapat mengetahui hubungan antarwaktu.

Contoh pada prediksi konsumsi listrik:

- Jam 08.00: konsumsi mulai naik.
- Jam 09.00: konsumsi tinggi karena aktivitas kantor dimulai.
- Jam 12.00: konsumsi dapat berubah karena istirahat siang.

Model perlu mengingat pola jam sebelumnya untuk memprediksi jam berikutnya. Hidden state memungkinkan hal tersebut.

7.2 Memori Jangka Panjang

Memori jangka panjang diperlukan ketika informasi penting berada jauh sebelum titik prediksi. Contohnya:

- Pada teks, subjek kalimat dapat berada di awal kalimat sedangkan kata kerja berada di akhir.
- Pada data medis, kondisi pasien beberapa hari sebelumnya dapat memengaruhi diagnosis saat ini.
- Pada cuaca, curah hujan beberapa hari sebelumnya dapat memengaruhi debit sungai.
- Pada saham, tren harga jangka panjang dapat memengaruhi pergerakan harga berikutnya.

LSTM dan GRU membantu model mempertahankan informasi penting tersebut.

8. Lima Studi Kasus RNN

8.1 Prediksi Konsumsi Listrik

- Judul: RNN(p) for power consumption forecasting
- Sumber: Springer, Decisions in Economics and Finance, 2026
- Tautan: https://www.link.springer.com/article/10.1007/s10203-026-00597-2

Studi ini menerapkan RNN dengan p lag waktu, disebut RNN(p), untuk memprediksi konsumsi listrik. Model diuji menggunakan dua dataset publik, yaitu beban listrik wilayah New England dan net load di London. Hasil penelitian menunjukkan bahwa RNN(p) memberikan akurasi forecasting yang baik sekaligus tetap memiliki tingkat interpretabilitas yang tinggi.

Relevansi: Studi ini menunjukkan bahwa RNN dapat digunakan untuk data deret waktu energi, di mana pola konsumsi masa lalu memengaruhi kebutuhan listrik di masa depan.

8.2 Pemantauan Kondisi Pembangkit Nuklir dan Mesin Berputar

- Judul: Elman’s recurrent neural network applications to condition monitoring in nuclear power plant and rotating machinery
- Penulis: S. Seker et al.
- Sumber: Engineering Applications of Artificial Intelligence, 2003
- Tautan: https://www.sciencedirect.com/science/article/pii/S0952197603001325

Penelitian ini menggunakan RNN Elman untuk pemantauan kondisi dan diagnosis pada sistem pembangkit nuklir serta mesin berputar. Pada aplikasi pertama, RNN digunakan untuk mendeteksi anomali pada simulasi operasi reaktor nuklir bersuhu tinggi. Pada aplikasi kedua, RNN digunakan untuk mendeteksi kerusakan bearing motor induksi melalui analisis koherensi antara sinyal arus motor dan getaran.

Relevansi: Kasus ini membuktikan bahwa RNN mampu mempelajari pola sinyal waktu dan mendeteksi perubahan abnormal pada sistem industri.

8.3 Prediksi Dampak Kebijakan Publik

- Judul: RNN-Based Counterfactual Prediction, With an Application to ...
- Sumber: Journal of the Royal Statistical Society: Series C, 2021
- Tautan: https://academic.oup.com/jrsssc/article/70/4/1124/7034010

Studi ini mengusulkan metode RNN untuk memprediksi hasil kontrafaktual, yaitu perkiraan kondisi yang mungkin terjadi jika suatu kebijakan tidak diterapkan. RNN dilatih menggunakan riwayat hasil dari unit kontrol, kemudian digunakan untuk menaksir efek intervensi kebijakan terhadap outcome dari waktu ke waktu.

Relevansi: Studi ini menunjukkan penggunaan RNN bukan hanya untuk forecasting, tetapi juga untuk evaluasi kebijakan berbasis data historis.

8.4 Prediksi Sindrom Napas Akut Berat (ARDS)

- Judul: Multitask Learning With Recurrent Neural Networks for Acute Respiratory Distress Syndrome Prediction Using Only Electronic Health Record Data

- Penulis: Carson Lam, Rahul Thapa, Jenish Maharjan, et al.
- Sumber: JMIR Medical Informatics, 2022
- Tautan: https://medinform.jmir.org/2022/6/e36202/

Penelitian ini menggunakan RNN untuk memprediksi ARDS berdasarkan data rekam medis elektronik. Dataset mencakup 40.073 kunjungan pasien dari tujuh rumah sakit. Model dilatih untuk mengklasifikasikan 13 label, termasuk ARDS, sepsis, hipoksemia, dan COVID-19. RNN multitugas mencapai AUROC 0,842 pada pengujian eksternal untuk prediksi ARDS dan mengungguli model XGBoost.

Relevansi: Data klinis bersifat berurutan, sehingga RNN dapat memanfaatkan perkembangan kondisi pasien dari waktu ke waktu untuk prediksi dini.

8.5 Keamanan Siber: Deteksi Penipuan dan Malware

- Judul: RNNSecureNet: Recurrent neural networks for Cyber security use-cases
- Sumber: arXiv, 2019
- Tautan: https://arxiv.org/pdf/1901.04281.pdf

Studi ini menerapkan RNN pada beberapa kasus keamanan siber, yaitu deteksi insiden, deteksi penipuan (fraud detection), dan klasifikasi malware Android. RNN digunakan karena aktivitas pengguna, transaksi, dan perilaku perangkat sering bersifat berurutan.

Relevansi: Pola serangan siber dan transaksi penipuan sering hanya terlihat jika model mampu menganalisis rangkaian aktivitas, bukan satu peristiwa secara terpisah.

9. Lima Studi Kasus LSTM

9.1 Prediksi Suhu Harian Berbasis IoT

- Judul: Using Long Short-Term Memory (LSTM) and Internet of Things (IoT) for Local Weather Forecasting
- Sumber: arXiv, 2021
- Tautan: https://arxiv.org/html/2102.02892

Penelitian ini mengembangkan kerangka kerja berbasis LSTM untuk prakiraan suhu per jam satu hari ke depan. Studi menggunakan data historis dan data IoT di New York City. LSTM dipilih karena mampu mempelajari pola suhu yang berulang serta hubungan antara kondisi cuaca sebelumnya dan suhu berikutnya.

Relevansi: Data cuaca adalah data deret waktu dengan pola harian, musiman, dan jangka panjang, sehingga sesuai untuk LSTM.

9.2 Prediksi Harga Saham

- Judul: A Long Short-Term Memory (LSTM) Neural Architecture for Analyzing and Predicting Stock Prices
- Sumber: SCITEPRESS, 2025
- Tautan: https://www.scitepress.org/Papers/2025/136919/136919.pdf

Studi ini menerapkan LSTM untuk menganalisis dan memprediksi harga saham perusahaan teknologi, termasuk Alphabet, Apple, NVIDIA, Meta, dan Tesla. LSTM digunakan untuk menangkap pola pergerakan harga historis dan ketergantungan temporal pada data pasar modal.

Relevansi: Harga saham merupakan data deret waktu yang dipengaruhi oleh tren jangka pendek maupun jangka panjang.

9.3 Prediksi Harga Listrik Hari Berikutnya

- Judul: Probabilistic Forecasting of Day-Ahead Electricity Prices
- Sumber: arXiv
- Tautan: https://ar5iv.labs.arxiv.org/html/2310.03339

Penelitian ini menggunakan LSTM untuk memprediksi harga listrik hari berikutnya. Model tidak hanya memprediksi nilai rata-rata harga, tetapi juga standar deviasinya, sehingga menghasilkan prakiraan probabilistik. Input yang digunakan meliputi beban listrik, prakiraan energi terbarukan, dan harga bahan bakar.

Relevansi: Harga listrik dipengaruhi oleh banyak faktor yang berubah sepanjang waktu, sehingga LSTM membantu menangkap dinamika pasar energi.

9.4 Prediksi Struktur Protein

- Judul: Capturing non-local interactions by long short-term memory bidirectional recurrent neural networks for improving prediction of protein secondary structure, backbone angles, contact numbers and solvent accessibility
- Sumber: Bioinformatics, Oxford Academic, 2017
- Tautan: https://academic.oup.com/bioinformatics/article/33/18/2842/3738544

Studi ini menggunakan LSTM bidirectional untuk memprediksi struktur sekunder protein, sudut backbone, jumlah kontak, dan aksesibilitas pelarut. LSTM dipilih karena mampu menangkap hubungan lokal maupun non-lokal di dalam sekuens asam amino.

Relevansi: Sekuens protein mirip dengan teks; posisi asam amino yang jauh dapat saling memengaruhi struktur dan fungsi protein.

9.5 Prediksi Penyakit dan Risiko Pascabedah

- Judul: Analysis and Prediction of Medical Time Series Data Based on LSTM
- Sumber: Springer, 2022
- Tautan: https://link.springer.com/chapter/10.1007/978-981-95-3320-6_23

Penelitian ini mengusulkan kerangka LSTM yang menggabungkan fusi multimodal dan transfer learning untuk prediksi penyakit serta penilaian risiko pascabedah. Model memanfaatkan sinyal fisiologis dinamis dan metadata pasien. Studi ini menggunakan kasus stroke iskemik sebagai salah satu penerapannya.

Relevansi: Kondisi pasien berkembang dari waktu ke waktu, sehingga LSTM membantu menghubungkan riwayat klinis dengan risiko yang akan datang.

10. Lima Studi Kasus GRU

10.1 Pemodelan Musik Polifonik dan Sinyal Bicara

- Judul: Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling
- Penulis: Junyoung Chung, Caglar Gulcehre, Kyunghyun Cho, Yoshua Bengio
- Sumber: arXiv, 2014
- Tautan: https://ar5iv.labs.arxiv.org/html/1412.3555

Studi ini merupakan salah satu paper penting dalam pengembangan GRU. Peneliti membandingkan GRU dan LSTM pada tugas pemodelan musik polifonik serta pemodelan sinyal bicara. Hasilnya menunjukkan bahwa GRU mampu memberikan performa kompetitif dibandingkan LSTM pada beberapa tugas pemodelan sekuens.

Relevansi: Musik dan suara memiliki struktur waktu yang panjang, sehingga cocok untuk menguji kemampuan GRU dalam menangkap dependensi temporal.

10.2 Prediksi Indeks Kualitas Udara

- Judul: A Novel Deep Learning Approach to Predict Air Quality Index
- Sumber: Springer, 2024
- Tautan: https://link.springer.com/chapter/10.1007/978-981-33-4673-4_29

Studi ini mengembangkan model prediksi Indeks Kualitas Udara (AQI) untuk kota Dhaka dan Chattogram di Bangladesh. Model yang digunakan mencakup GRU, LSTM, dan arsitektur hibrida. GRU berperan menangkap pola perubahan kualitas udara dari data historis.

Relevansi: Kualitas udara dipengaruhi oleh kondisi beberapa jam atau hari sebelumnya, seperti emisi kendaraan, cuaca, dan aktivitas industri.

10.3 Prediksi Konsentrasi Karbon Monoksida

- Judul: Improving Urban Air Quality Prediction Using Bidirectional GRU: A Case Study of CO Concentration to Support Education in Yogyakarta
- Sumber: Jurnal LITE, Universitas Negeri Malang
- Tautan: https://journal2.um.ac.id/index.php/lite/article/download/55556/13933

Penelitian ini menggunakan Bidirectional GRU untuk memprediksi konsentrasi karbon monoksida (CO) di Yogyakarta. Pendekatan bidirectional memungkinkan model membaca data dari dua arah, yaitu masa lalu ke masa depan dan masa depan ke masa lalu, sehingga konteks temporal lebih kaya.

Relevansi: Prediksi kualitas udara perkotaan membutuhkan pemahaman terhadap pola emisi, lalu lintas, dan kondisi atmosfer yang berubah sepanjang waktu.

10.4 Prediksi Muka Air Tanah

- Judul: Groundwater level prediction with meteorologically sensitive Gated Recurrent Unit (GRU) neural networks
- Sumber: ScienceDirect
- Tautan: https://www.sciencedirect.com/science/article/abs/pii/S0022169422008344

Studi ini menerapkan GRU untuk memprediksi level air tanah dengan mempertimbangkan faktor meteorologi. GRU digunakan untuk memodelkan hubungan antara curah hujan, suhu, dan variabel iklim lainnya terhadap perubahan muka air tanah.

Relevansi: Perubahan air tanah bersifat lambat dan dipengaruhi oleh akumulasi kondisi cuaca dalam jangka waktu tertentu, sehingga memerlukan model dengan memori temporal.

10.5 Prediksi Sisa Umur Mesin

- Judul: Few-shot RUL prediction for engines based on CNN-GRU
- Sumber: PMC, 2024
- Tautan: https://pmc.ncbi.nlm.nih.gov/articles/PMC11239844/

Penelitian ini menggabungkan CNN dan GRU untuk memprediksi Remaining Useful Life (RUL) mesin dengan pendekatan few-shot learning. CNN digunakan untuk mengekstraksi fitur dari data sensor, sedangkan GRU digunakan untuk memodelkan perkembangan kondisi mesin dari waktu ke waktu.

Relevansi: Kondisi mesin berubah secara bertahap; GRU membantu model mengenali pola degradasi sebelum kegagalan terjadi.

11. Kesimpulan

RNN, LSTM, dan GRU sama-sama menggunakan konsep hidden state untuk menyimpan informasi dari waktu sebelumnya. Perbedaannya adalah RNN hanya mengandalkan hidden state sederhana, sedangkan LSTM dan GRU menambahkan gerbang untuk mengatur informasi yang perlu diingat, diperbarui, atau dibuang.

LSTM lebih kuat untuk dependensi jangka panjang karena memiliki cell state serta tiga gerbang, sedangkan GRU lebih efisien karena hanya menggunakan dua gerbang tanpa cell state terpisah. Dalam praktiknya, pilihan model bergantung pada panjang urutan, kompleksitas data, jumlah data pelatihan, dan keterbatasan komputasi.

Bukti dari berbagai studi kasus menunjukkan bahwa RNN banyak digunakan untuk forecasting dan deteksi anomali, LSTM unggul pada data berurutan kompleks seperti cuaca, saham, teks, medis, dan biologi, sedangkan GRU banyak diterapkan pada prediksi lingkungan, energi, suara, dan pemeliharaan mesin.

Daftar Pustaka Singkat

- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling. arXiv. https://ar5iv.labs.arxiv.org/html/1412.3555
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation. Dirujuk dalam A Critical Review of Recurrent Neural Networks for Sequence Learning. https://ar5iv.labs.arxiv.org/html/1506.00019
- Lam, C., Thapa, R., Maharjan, J., et al. (2022). Multitask Learning With Recurrent Neural Networks for Acute Respiratory Distress Syndrome Prediction Using Only Electronic Health

Record Data. JMIR Medical Informatics, 10(6), e36202. https://medinform.jmir.org/2022/6/e36202/

- Seker, S., et al. (2003). Elman’s recurrent neural network applications to condition monitoring in nuclear power plant and rotating machinery. Engineering Applications of Artificial Intelligence. https://www.sciencedirect.com/science/article/pii/S0952197603001325
- RNN(p) for power consumption forecasting. (2026). Decisions in Economics and Finance, Springer. https://www.link.springer.com/article/10.1007/s10203-026-00597-2